

Report progetto R di Analisi Multivariata

Alessio Buglione

Problema 1:


a) Analisi descrittive

Dopo aver importato il dataset “heptathlon” ed aver eliminato la variabile *score* dal dataset, ho separato i nomi delle atlete dai dati quantitativi per fare analisi descrittive con il comando *summary*.

hurdles	highjump	shot	run200m	longjump	javelin	run800m
Min. :12.69	Min. :1.500	Min. :10.00	Min. :22.56	Min. :4.880	Min. :35.68	Min. :124.2
1st Qu.:13.47	1st Qu.:1.770	1st Qu.:12.32	1st Qu.:23.92	1st Qu.:6.050	1st Qu.:39.06	1st Qu.:132.2
Median :13.75	Median :1.800	Median :12.88	Median :24.83	Median :6.250	Median :40.28	Median :134.7
Mean :13.84	Mean :1.782	Mean :13.12	Mean :24.65	Mean :6.152	Mean :41.48	Mean :136.1
3rd Qu.:14.07	3rd Qu.:1.830	3rd Qu.:14.20	3rd Qu.:25.23	3rd Qu.:6.370	3rd Qu.:44.54	3rd Qu.:138.5
Max. :16.42	Max. :1.860	Max. :16.23	Max. :26.61	Max. :7.270	Max. :47.50	Max. :163.4

Misure descrittive come valore minimo, valore massimo, mediana e scarto interquartile possono essere rappresentate con un boxplot, per fare questo ho utilizzato la matrice dei dati standardizzati per confrontare tra loro le variabili in quanto i valori osservati non sono più influenzati dalle unità di misura.

Boxplot delle discipline




b) Analisi delle componenti principali

Per procedere con l'analisi in componenti principali standardizzate ho dovuto prima ricavare la matrice di correlazione dei dati ($cor(X)$) e la matrice dei suoi autovettori (attraverso il comando *eigen*); eseguendo il prodotto scalare tra questa matrice e la matrice dei dati standardizzati ho ottenuto le componenti principali standardizzate. Per scegliere quante componenti principali considerare ho valutato il peso che ognuna di queste ha sulla variabilità totale e la sua cumulata:

```
0.637182165 0.170617222 0.074430590 0.065309546 0.035038106 0.010422226 0.007000144  
0.6371822 0.8077994 0.8822300 0.9475395 0.9825776 0.9929999 1.0000000
```


Considero le prime due componenti principali che spiegano l'80% della variabilità totale.

Le varianze delle varie componenti principali sono visualizzabili con uno scree plot:



Può essere interessante analizzare anche la correlazione tra le variabili e le prime due componenti principali: nel grafico seguente una variabile che compare nel primo quadrante ha correlazione positiva con entrambe le componenti principali, viceversa


se una variabile compare nel terzo quadrante ha correlazione negativa con entrambe le componenti principali.



La prima CP è correlata positivamente con la corsa 800m, corsa ad ostacoli e corsa 200m mentre è correlata negativamente con tutte le altre discipline; invece la seconda CP è correlata positivamente con il salto il lungo, salto in alto e corsa 200m.

Un altro grafico importante è il grafico a dispersione in cui sull'asse X compaiono i valori della prima CP e sull'asse Y i valori della seconda CP per ogni osservazione, questo ci permette di visualizzare quali sono le unità che presentano valori maggiori per ogni componente principale:

Proiezione delle atlete sulle prime 2 CP




La proiezione delle atlete sul piano individuato dalle prime due componenti principali evidenzia una marcata eterogeneità nei profili prestazionali. In particolare, la distribuzione delle osservazioni riflette differenti combinazioni di performance nelle discipline considerate, indicando la presenza di atlete con specializzazioni più orientate verso specifici gruppi di prove


c) Raggruppamento delle atlete in gruppi



Per raggruppare le unità in gruppi ho creato la matrice delle distanze, per farlo ho utilizzato la funzione *dist*. In seguito con il comando *hclust* ho effettuato i raggruppamenti rappresentati da questi dendrogrammi:

Legame singolo



Legame completo








Il metodo di Ward risulta il più appropriato in questo contesto, in quanto tende a minimizzare l'incremento della devianza interna ai gruppi ad ogni fusione, producendo cluster omogenei e ben separati.

d) Raggruppamento in gruppi con criterio del massimo salto


Per individuare i gruppi ottenuti con il criterio del massimo salto della distanza di fusione ho calcolato le differenze tra le distanze di fusione per ogni metodo di clustering e grazie alla funzione "*which.max*" ho individuato il salto maggiore. Nei seguenti grafici si possono visualizzare i gruppi ottenuti interrompendo il raggruppamento quando si presenta il salto maggiore:



Metodo del centroide – massimo salto



Metodo di Ward – massimo salto



Applicando il criterio del massimo salto ai diversi metodi di clustering gerarchico, si osserva come il metodo di Ward fornisca la partizione più chiara e interpretabile, individuando cluster omogenei e ben separati. Gli altri metodi, in particolare il legame singolo, mostrano strutture meno stabili, confermando l'adeguatezza del metodo di Ward in questo contesto.

Problema 2:


a) Analisi descrittive

Dopo aver importato il dataset "wine", ho identificato la variabile qualitativa di gruppo, corrispondente alla tipologia di vino, e separato tale variabile dai dati quantitativi. Successivamente, ho costruito la matrice delle variabili quantitative, sulla quale sono state effettuate le analisi descrittive mediante il comando *summary*.

alcohol	malic_acid	ash	alcalinity_of_ash	magnesium	total_phenols	flavanoids	nonflavanoid_phenols
Min. :11.03	Min. :0.740	Min. :1.360	Min. :10.60	Min. : 70.00	Min. :0.980	Min. :0.340	Min. :0.1300
1st Qu.:12.36	1st Qu.:1.603	1st Qu.:2.210	1st Qu.:17.20	1st Qu.: 88.00	1st Qu.:1.742	1st Qu.:1.205	1st Qu.:0.2700
Median :13.05	Median :1.865	Median :2.360	Median :19.50	Median : 98.00	Median :2.355	Median :2.135	Median :0.3400
Mean :13.00	Mean :2.336	Mean :2.367	Mean :19.49	Mean : 99.74	Mean :2.295	Mean :2.029	Mean :0.3619
3rd Qu.:13.68	3rd Qu.:3.083	3rd Qu.:2.558	3rd Qu.:21.50	3rd Qu.:107.00	3rd Qu.:2.800	3rd Qu.:2.875	3rd Qu.:0.4375
Max. :14.83	Max. :5.800	Max. :3.230	Max. :30.00	Max. :162.00	Max. :3.880	Max. :5.080	Max. :0.6600

proanthocyanins	color_intensity	hue	od280	proline
Min. :0.410	Min. :1.280	Min. :0.4800	Min. :1.270	Min. : 278.0
1st Qu.:1.250	1st Qu.: 3.220	1st Qu.:0.7825	1st Qu.:1.938	1st Qu.: 500.5
Median :1.555	Median : 4.690	Median :0.9650	Median :2.780	Median : 673.5
Mean :1.591	Mean : 5.058	Mean :0.9574	Mean :2.612	Mean : 746.9
3rd Qu.:1.950	3rd Qu.: 6.200	3rd Qu.:1.1200	3rd Qu.:3.170	3rd Qu.: 985.0
Max. :3.580	Max. :13.000	Max. :1.7100	Max. :4.000	Max. :1680.0

Oltre a questa analisi descrittiva, ho utilizzato anche un boxplot della matrice dei dati standardizzati:



b) Matrici di devianza between B e within W

Per determinare le matrici di devianza within e between, sono state calcolate le matrici di varianza-covarianza dei dati standardizzati all'interno di ciascun gruppo e sull'intero campione. Utilizzando il numero di osservazioni per ciascun gruppo ho costruito la matrice di devianza totale e la matrice di devianza within; la matrice di devianza between è stata infine ottenuta come differenza tra la devianza totale e la devianza within.

-Matrice di devianza within:

	alcohol	malic_acid	ash	alcalinity_of_ash	magnesium	total_phenols	flavanoids	nonflavanoid_phenols	proanthocyanins	color_intensity	hue	od280	proline
alcohol	69.5824661	1.577054	-10.457582	-6.275212	0.2706597	9.333477	4.884140	-1.689724	6.316451	22.916627	0.7375944	-1.513628	8.376660
malic_acid	1.5770543	124.454145	12.214053	19.454986	-9.7541912	-3.625554	-1.475635	12.807462	4.708314	-17.480653	-28.8750537	10.266028	-16.444783
ash	-10.4575824	12.214053	153.626171	92.478811	30.7951664	16.480938	19.139936	35.984064	2.987608	2.694910	6.4807861	9.803303	-1.014803
alcalinity_of_ash	-6.2752117	19.454986	92.478811	125.637173	11.8795311	9.094276	12.927618	19.753899	8.489407	-2.300955	-2.2538133	16.653139	-5.463540
magnesium	0.2706597	-9.754191	30.795166	11.879531	154.9841331	11.299095	8.180023	-28.261737	27.838242	9.367676	6.7628244	-4.851649	18.530421
total_phenols	9.3334768	-3.625554	16.480938	9.094276	11.2990951	85.456287	45.156090	-17.380537	44.869153	24.000195	-1.7924653	23.576244	7.454631
flavanoids	4.8841401	-1.475635	19.139936	12.927618	8.1800235	45.156090	48.183738	-21.492372	39.117737	21.665157	-3.2241645	16.745872	1.905900
nonflavanoid_phenols	-1.6897236	12.807462	35.984064	19.753899	-28.2617374	-17.380537	-21.492372	134.585652	-21.228504	-0.916306	8.3578579	-19.947408	-2.202131
proanthocyanins	6.3164512	4.708314	2.987608	8.489407	27.8382425	44.869153	39.117737	-21.228504	131.504781	30.229479	-8.4351234	18.277223	11.148497
color_intensity	22.9166268	-17.480653	2.694910	-2.300955	9.3676760	24.000195	21.665157	-0.916306	30.229479	74.400466	-13.5391951	-7.049620	16.322809
hue	0.7375944	-28.875054	6.480786	-2.253813	6.7628244	-1.792465	-3.224164	8.357858	-8.435123	-13.539195	82.0239533	-3.609379	10.918867
od280	-1.5136284	10.266028	9.803303	16.653139	-4.8516489	23.576244	16.745872	-19.947408	18.277223	-7.049620	-3.6093787	55.816378	-8.564949
proline	8.3766595	-16.444783	-1.014803	-5.463540	18.5304215	7.454631	1.905900	-2.202131	11.148497	16.322809	10.9188670	-8.564949	52.425294

-Matrice di devianza between:

	alcohol	malic_acid	ash	alkalinity_of_ash	magnesium	total_phenols	flavanoids	nonflavanoid_phenols	proanthocyanins	color_intensity	hue	od280	proline
alcohol	107.41753	15.13120427	47.900976	-48.636408	47.66062633	41.83742	37.032102	-25.909792	17.879079	73.789836	-13.436848	14.318373	105.56179
malic_acid	15.13120	52.54585544	16.821996	31.609586	0.09439921	-55.69900	-71.272531	39.049491	-43.780389	61.551059	-70.474283	-75.527774	-17.54109
ash	47.90098	16.82199554	23.373829	-14.002819	19.93067796	6.34844	1.228742	-3.021275	-1.279215	43.128135	-19.696825	-9.111015	40.59665
alkalinity_of_ash	-48.63641	31.60958578	-14.002819	51.362827	-26.629488	-65.93133	-75.120083	44.306246	-43.416257	5.616516	-46.236261	-65.641172	-72.52212
magnesium	47.66063	0.09439921	19.930678	-26.629488	22.01586690	26.64992	26.473704	-17.102309	14.011745	26.023475	3.042656	16.534346	51.09268
total_phenols	41.83742	-55.69900482	6.348440	-65.931333	26.64992342	91.54371	107.871650	-62.258011	63.527963	-33.759341	78.554062	100.314794	80.71170
flavanoids	37.03210	-71.27253141	1.228742	-75.120083	26.47370377	107.87165	128.816262	-73.715859	76.408706	-52.176310	99.419871	122.587448	85.56628
nonflavanoid_phenols	-25.90979	39.04949097	-3.021275	44.306246	-17.10230922	-62.25801	-73.715859	42.414348	-43.526078	25.529397	-54.845073	-69.131310	-52.91305
proanthocyanins	17.87908	-43.78038945	-1.279215	-43.416257	14.01174545	63.52796	76.408706	-43.526078	45.495219	-34.698717	60.746456	73.597653	47.33526
color_intensity	73.78984	61.55105885	43.128135	5.616516	26.02347514	-33.75934	-52.176310	25.529397	-34.698717	102.599534	-78.821740	-68.850625	39.62691
hue	-13.43685	-70.47428322	-19.696825	-46.236261	3.04265621	78.55406	99.419871	-54.845073	60.746456	-78.821740	94.976047	103.697267	30.88560
od280	14.31837	-75.52777354	-9.111015	-65.641172	16.53434558	100.31479	122.587448	-69.131310	73.597653	-68.850625	103.697267	121.183622	63.92366
proline	105.56179	-17.54108708	40.596652	-72.522117	51.09267884	80.71170	85.566283	-52.913048	47.335259	39.626911	30.885603	63.923660	124.57471

c) Analisi discriminante lineare di Fisher


L'analisi discriminante lineare (svolta con la funzione "lda") è stata utilizzata per classificare le osservazioni nei tre gruppi di vino, individuando combinazioni lineari delle variabili che massimizzano la separazione tra i gruppi. Visto che il numero di gruppi è pari a tre, si ottengono due funzioni discriminanti:

$$\begin{matrix} \text{LD1} & \text{LD2} \\ 0.6875 & 0.3125 \end{matrix}$$

La prima spiega circa il 68.8% della capacità discriminante totale, la seconda spiega il restante 31.2%. Le osservazioni sono state quindi riclassificate mediante la funzione predict, che assegna ciascuna unità al gruppo con probabilità a posteriori massima. La matrice di confusione relativa all'errore apparente mostra una classificazione perfetta delle osservazioni mentre dalla matrice di confusione LOOCV emerge che due osservazioni su 178 vengono riclassificate.

Osservato	Predetto			Osservato	Predetto		
	Barbera	Barolo	Grignolino		Barbera	Barolo	Grignolino
Barbera	48	0	0	Barbera	48	0	0
Barolo	0	59	0	Barolo	0	59	0
Grignolino	0	0	71	Grignolino	1	1	69

Il tasso di errore LOOCV risulta pari a circa l'1.1%, confermando l'elevata capacità discriminante del modello.



Il boxplot dei punteggi sulla prima funzione discriminante mostra una separazione netta tra i gruppi, con una minima sovrapposizione limitata a poche osservazioni estreme. Tali osservazioni corrispondono ai casi che spiegano la presenza dell'errore di riclassificazione LOOCV pari a circa l'1.1%.